
Examen LMAFY1101

Exploration de données et introduction à l'inférence statistique

INSTRUCTIONS

Merci de commencer par lire attentivement ce qui suit

1. Indiquer votre nom et votre prénom **sur chaque feuille de réponse**.
2. Le port d'une montre connectée, d'un smartphone ou l'utilisation de tout autre technologie permettant la communication avec l'extérieur est strictement **interdit**. Le non respect de cette consigne entrainera **l'annulation de votre examen!**
3. **Justifiez chaque réponse** en détaillant votre raisonnement. La réponse finale n'est pas la plus intéressante pour nous. Nous devons apprécier l'état de vos connaissances. Faites donc un effort pour être **clair et lisible**.
4. À la fin de l'examen, merci de **rendre tous les documents** y compris vos feuilles de brouillon.
5. Créer dans W:/Réponses un sous-répertoire NOM_PRENOM (votre nom et prénom sans accent). Copier dans votre dossier, celui que vous venez de créer, le fichier Data.RData se trouvant dans W:/Questions .
6. Ouvrir un nouveau fichier dans Word et sauvegarder le dans votre répertoire. Ce fichier sera **uniquement** utilisé pour y insérer vos **graphiques**. **Chaque graphique doit être identifié** à l'aide d'un nom/numéro unique.
7. Démarrer RStudio et créer un nouveau script (File/New File/R script). **Sauvegarder votre script au fur et à mesure dans votre répertoire**.
8. En remplaçant NOM_PRENOM par votre nom et prénom (sans accent), taper en RStudio la commande suivante:

```
setwd("W:/Réponses/NOM_PRENOM")
```

9. ~~Exécuter le code suivant pour importer le(s) jeu(x) de données et charger des packages~~

```
load("Data.RData")  
if (!require("ggplot2")) install.packages("ggplot2"); require("ggplot2")
```

Téléchargez le fichier Data.RData depuis Moodle et ouvrez-le dans RStudio.

Le package ggplot2 ne fait pas partie du programme de cette année, mais vous pouvez l'utiliser si vous le souhaitez. Les équivalents de tous les graphiques de ce document peuvent être réalisés avec R de base (sans installer de package).

Bonne chance !

EXERCICE 1 [6 POINTS]

Le jeu de données `Mammiferes` présente les résultats d'une étude sur 572 espèces de mammifères. On y a calculé la masse [`Masse`] (en grammes) de l'animal ainsi que son métabolisme [`Metabolisme`] de base et sa longévité [`Longevite`] (en mois). Commencer par examiner ces données en exécutant les commandes suivantes:

```
head(Mammiferes)
str(Mammiferes)
```

- (1.1) Ajoutez à votre jeu de données une nouvelle colonne donnant le métabolisme par gramme de chaque animal. Calculez-en sa moyenne et sa médiane. Peut-on considérer que la distribution est symétrique ? Justifiez votre réponse à l'aide de deux graphiques différents. [1 point]



SOLUTION

```
Mammiferes$MetGram <- Mammiferes$Metabolisme/Mammiferes$Masse
summary(Mammiferes$MetGram)
```

```
Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
0.0215  0.4565  0.8710   1.1144  1.4022 10.6190
```

```
ggplot(Mammiferes) +
  aes(x=MetGram) + geom_histogram(binwidth=0.21)
ggplot(Mammiferes, aes(x="", y=MetGram)) + geom_boxplot()
```

Warning: Removed 247 rows containing non-finite values (stat_boxplot).




Comme on le voit sur ces graphiques, la distribution n'est pas symétrique (asymétrie à droite).

- (1.2) Transformez la variable métabolisme par gramme en prenant (1) son logarithme et (2) sa racine carrée. Dans le but de "symétriser" cette variable, laquelle de ces deux transformations choisiriez-vous? Justifiez à l'aide de graphiques. [1 point]

SOLUTION

```
Mammiferes$logMetGram <- log(Mammiferes$MetGram)
Mammiferes$sMetGram <- sqrt(Mammiferes$MetGram)
ggplot(Mammiferes) +
  aes(x=logMetGram) + geom_histogram(binwidth= 0.33)
ggplot(Mammiferes) +
  aes(x=sMetGram) + geom_histogram(binwidth=0.15)
```



Nous observons une meilleure symétrie avec le logarithme.

- (1.3) La variable Longevite présente des observations manquantes. Combien y en a-t-il ? [0.5 point]

SOLUTION

0.5

```
summary(Mammiferes$Longevite)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.	NA's
9.6	54.0	120.0	149.3	213.6	720.0	247

```
# ou
```

```
sum(is.na(Mammiferes$Longevite))
```

```
[1] 247
```

- (1.4) Effectuez une **régression linéaire** pour expliquer la longévité en fonction du métabolisme par gramme. Écrivez le modèle estimé. Calculez le coefficient de détermination et interprétez-le. [1 point]

SOLUTION

```
reg1.4 <- lm(Longevite~MetGram,data=Mammiferes)
coef(reg1.4)
```

```
(Intercept)      MetGram
  188.60564    -38.11557
```

```
reg1.4_r2 <- summary(reg1.4)$r.squared
reg1.4_r2
```

```
[1] 0.169222
```

Le modèle estimé s'écrit $\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X$, où $\hat{\beta}_0 = 188.61$ et $\hat{\beta}_1 = -38.12$.

Le coefficient de détermination vaut **0.17**. Il s'agit du pourcentage de variabilité de la variable Longévité que nous parvenons à expliquer avec notre modèle.

- (1.5) Votre modèle s'ajuste-t-il correctement aux données ? Si non, proposez une transformation sur la longévité et/ou le métabolisme pour obtenir un modèle s'ajustant mieux aux données. Justifiez vos choix graphiquement et numériquement et écrivez formellement le modèle final estimé. [1.5 point]

SOLUTION

Commençons par examiner l'ajustement du modèle aux données.

```
ggplot(Mammiferes)+
  aes(x=MetGram,y=Longevite)+
  geom_point()+
  stat_smooth(method="lm",
  formula=y~x,
  se=FALSE)
```



Warning: Removed 247 rows containing non-finite values (stat_smooth).

Warning: Removed 247 rows containing missing values (geom_point).

```
ggplot(reg1.4)+
  aes(x=.fitted,y=.resid)+
  labs(x="valeurs prédites",y="résidus")+
  geom_point()+
  geom_smooth(se=FALSE)
```

'geom_smooth()' using method = 'loess' and formula 'y ~ x'

0.25



0.25

Le modèle s'ajuste très mal aux données. Afin de résoudre ce problème, nous proposons transformation logarithmique pour les deux variables concernées.

0.25

```
Mammiferes$logMetGram <- log(Mammiferes$MetGram)
Mammiferes$logLongevite <- log(Mammiferes$Longevite)
```

```
ggplot(Mammiferes)+
  aes(x=logMetGram,y=logLongevite)+
  geom_point()+
  stat_smooth(method="lm",
  formula=y~x,
  se=FALSE)
```

Warning: Removed 247 rows containing non-finite values (stat_smooth).

Warning: Removed 247 rows containing missing values (geom_point).

```
reg1.5 <- lm(logLongevite ~ logMetGram,data=Mammiferes)
coef(reg1.5)
```

```
(Intercept)  logMetGram
 4.3263278  -0.6382576
```


```
summary(reg1.5)$r.squared
```

```
[1] 0.4579174
```

```
ggplot(reg1.5)+
  aes(x=.fitted,y=.resid)+
  labs(x="valeurs prédites",y="résidus")+
  geom_point()+
  geom_smooth(se=FALSE)
```

'geom_smooth()' using method = 'loess' and formula 'y ~ x'

0.25



0.25

0.25

Le modèle s'ajuste bien mieux aux données (coefficient de détermination vaut 0.46 ; voir aussi le graphique des résidus).

Le modèle estimé s'écrit $\log(\hat{Y}) = \hat{\beta}_0 + \hat{\beta}_1 \log(X)$, où $\hat{\beta}_0 = 4.33$ et $\hat{\beta}_1 = -0.64$.

- (1.6) Votre animal de compagnie préféré pèse 127g et a un métabolisme de base de 135. Prédisez sa longévité (en mois) en utilisant votre modèle final. [1 point]

SOLUTION

```
newdata <- log(135/127)
prediction <- exp(predict(reg1.5, new = data.frame(logMetGram = newdata)))
prediction
```

1

1
72.7725

On prédit une longévité de $\exp(\hat{\beta}_0 + \hat{\beta}_1 \log(135/127)) = 72.77$ mois.

EXERCICE 2 [5 POINTS]

Vous êtes gérant d'un bar et vous voulez déterminer si votre matériel est suffisant pour servir vos clients. Plus précisément, vous voulez connaître le débit Q (en litres par minute) de votre pompe à bière. Pour ce faire, vous mesurez 30 fois le diamètre D (en millimètres) de la pompe ainsi que la vitesse d'écoulement F de la bière (en mètres par minute). Le débit est dès lors donné par la formule suivante $Q = \frac{\pi}{4000} D^2 F$. Les résultats de votre expérience sont rassemblés dans la base de données `biere`. Commencer par examiner ces données en exécutant les commandes suivantes:


```
head(biere)
str(biere)
```

- (2.1) La vitesse d'écoulement est supposée suivre une distribution normale. Au vu des données, cette hypothèse est-elle plausible ? Justifiez votre réponse. [1 point]

SOLUTION

```
qqnorm(biere$ecoulement,main="qqplot de l'écoulement")
qqline(biere$ecoulement)
```

qqplot de l'écoulement



Oui, l'hypothèse de normalité semble plausible

- (2.2) On sait avec certitude que la vitesse d'écoulement est inférieure à 27 mètres par minute. Calculez la probabilité que cette vitesse soit supérieure à 24 mètres par minute. Pour ce faire, approchez l'espérance et la variance par la moyenne et la variance de votre échantillon. [1 point]

SOLUTION

Rappelons que la vitesse d'écoulement est modélisée par la variable aléatoire F . Nous venons de voir que sa distribution pouvait être approchée par une normale. Nous avons donc $F \sim N(\mu, \sigma^2)$. Par ailleurs, nous approchons μ par $\bar{F}$ et σ^2 par S_F^2 . Nous recherchons

$$P(F > 24 | F < 27) = \frac{P(24 < F < 27)}{P(F < 27)}.$$

La réponse est donnée par le code suivant

```
mean.F <- mean(biere$ecoulement)
sd.F <- sd(biere$ecoulement)
p.num <- pnorm(27,mean.F,sd.F)-pnorm(24,mean.F,sd.F)
p.denom <- pnorm(27,mean.F,sd.F)
```

0.5

```
p.cherchee <- p.num/p.denom
p.cherchee
```

```
[1] 0.3740499
```

Nous obtenons une probabilité de 0.37.

- (2.3) Proposez une estimation pour le diamètre de la pompe et, supposant la normalité des données, construisez un intervalle de confiance à 95% autour de cette estimation. [1 point]

SOLUTION

```
n <- nrow(biere)
mean.D <- mean(biere$diametre)
mean.D
```

```
[1] 7.032133
```

0.25

```
sd.Dbar <- sd(biere$diametre)/sqrt(n)
IC.D <- mean.D+c(-1,1)*sd.Dbar*qt(0.975,n-1)
IC.D
```

0.25

```
[1] 6.967869 7.096398
```

La meilleure estimation est donnée par $\bar{D} = 7.03$ et l'intervalle de confiance est donné par $IC_{0.95} = [\bar{D} \pm t_{n-1;0.975} \frac{S_D}{\sqrt{n}}] = [6.97, 7.10]$

0.5


- (2.4) À l'aide de **deux approches différentes**, proposez une estimation pour le débit et quantifiez l'incertitude qui y est associée. Quelle approche est la plus pertinente? Justifiez votre réponse. [2 point]

SOLUTION

Approche 1: Calcul direct. Puisqu'on dispose de toutes les mesures, on peut alors calculer un IC pour μ_{debit} sans aucune difficulté !

0.25

```
biere<-transform(biere, debit=(pi/4000)*(diametre^2)*ecoulement)
qqnorm(biere$debit,main="qqplot de l'écoulement")
qqline(biere$debit)
```

```
mean.Deb <- mean(biere$debit)
mean.Deb
```

0.25

[1] 0.9648981

```
sd.Debbar <- sd(biere$debit)/sqrt(n)
sd.Debbar
```

0.5

[1] 0.0351723

```
mean.Deb+c(-1,1)*sd.Debbar
```

[1] 0.9297258 1.0000704

Approche 2: Propagation des erreurs. (sans l'utilisation des données brutes)

La meilleure estimation est donnée par $Z = \frac{\pi}{4000} \overline{D}^2 \overline{F}$. En ce qui concerne l'incertitude, on peut utiliser la formule de propagation des erreurs

0.25

$$\sigma_Z = \sqrt{\left(\frac{\pi}{4000}\right)^2 \left\{ (\overline{D}^2)^2 \sigma_F^2 + (2\overline{D} \overline{F})^2 \sigma_D^2 \right\}}$$

```
Z <- (pi/4000)*mean.D^2*mean.F
```

0.25

[1] 0.9617161

```
sd.Fbar <- sd.F/sqrt(n)
sigma_Z <- sqrt((pi/4000)^2*((mean.D^2)^2*sd.Fbar^2 + (2*mean.D*mean.F)^2*sd.Dbar^2))
a_Z
```

[1] 0.03295216

```
Z+c(-1,1)*sigma_Z
```

[1] 0.9287639 0.9946682

nous obtenons $Z = 0.96$ et $\sigma_Z = 0.03$.

L'approche 1 est plus pertinente puisqu'elle se base sur des formules exactes et non pas des approximations (souvent biaisées !).

EXERCICE 3 [4 POINTS]

Sur 100 jours différents, un ingénieur de la circulation compte le nombre de voitures qui traversent une certaine intersection entre 5h et 5h05. Les résultats sont présentés dans le tableau suivant.

Nombre de voitures	Nombre de jours	Proportion de jours
0	36	0.36
1	28	0.28
2	15	0.15
3	10	0.10
4	7	0.07
5	4	0.04

Soit X le nombre de voitures passant par l'intersection, entre 5h et 5h05, à un jour choisi au hasard. Quelqu'un suggère de modéliser la distribution de X par $P(X = x) = (0.2)(0.8)^x$, $x = 0, 1, \dots$. Une autre personne suggère d'utiliser $P(X = x) = (0.4)(0.6)^x$, $x = 0, 1, \dots$.

(3.1) Quelle modélisation semble être la meilleure ? Justifiez votre réponse numériquement et graphiquement. [2 points]

SOLUTION


On peut calculer et comparer les probabilités théoriques avec les proportions observées.

```
Nv<-0:5
Nj<-c(36,28,15,10,7,4)
Pj<-Nj/100
P1<-0.2*(0.8)^Nv
P2<-0.4*(0.6)^Nv
dt<-data.frame(Nv,Nj,Pj,P1,P2)
dt
```

0.5

Nv	Nj	Pj	P1	P2
0	36	0.36	0.20	0.40
1	28	0.28	0.16	0.24
2	15	0.15	0.13	0.14
3	10	0.10	0.10	0.09
4	7	0.07	0.08	0.05
5	4	0.04	0.07	0.03

```
ppplot<-qplot(Nv,Pj, data=dt, geom="col", width = 0.1, fill=I("skyblue"))+
geom_point(aes(y=P1, shape="P1"), size=I(1.5)) +
geom_point(aes(y=P2, shape="P2"), size=I(1.5)) +
labs(x="Nv", y="Pj", shape=NULL)
ppplot
```



0.5

0.5

```
c(sum((Pj-P1)^2), sum((Pj-P2)^2))
c(sum(abs(Pj-P1)), sum(abs(Pj-P2)))
```

```
[1] 0.041283934 0.003829884
```

```
0.341856 0.126656
```

La deuxième proposition semble être meilleure.

(3.2) En justifiant votre réponse, proposez une modélisation alternative qui tient compte de la nature des données récoltées. S'il le faut, calculez le(s) paramètre(s) de votre distribution.

[1 point]

0.5

On peut modéliser la distribution de X par une Poisson, i.e. $P(X = x) = \frac{\lambda^x}{x!} e^{-\lambda}$, $x = 0, 1, \dots$. La moyenne λ peut être estimée par la moyenne des observations

0.5

```
lam<-sum(Nv*Nj)/sum(Nj)
lam
[1] 1.36
```

(3.3) Comparez votre modélisation aux deux autres et concluez. [1 point]

SOLUTION


```
Poi<-dpois(Nv,lam)
data.frame(dt,Poi)
```

0.25

Nv	Nj	Pj	P1	P2	Poi
0	36	0.36	0.20	0.40	0.26
1	28	0.28	0.16	0.24	0.35
2	15	0.15	0.13	0.14	0.24
3	10	0.10	0.10	0.09	0.11
4	7	0.07	0.08	0.05	0.04
5	4	0.04	0.07	0.03	0.01

```
pplot +
geom_point(aes(y=Poi, shape="Poi"), size=I(1.5))
```

0.25



0.25

```
c(sum((Pj-P1)^2), sum((Pj-P2)^2), sum((Pj-Poi)^2) )
```

```
[1] 0.041283934 0.003829884 0.025157142
```

```
c(sum(abs(Pj-P1)), sum(abs(Pj-P2)), sum(abs(Pj-Poi)) )
```

```
[1] 0.3418560 0.1266560 0.3308247
```

0.25

Selon cette analyse, la deuxième proposition semble être toujours la meilleure.

EXERCICE 4 [5 POINTS]

Des puces électroniques sont échantillonnées au hasard une par une parmi une large population et testées pour déterminer si elles sont acceptables pour une application donnée. Il est connu que nonante pour cent de ces puces sont acceptables.

(4.1) Quelle est la probabilité que la première puce tirée soit inacceptable et que la seconde soit acceptable ? [1 point]

SOLUTION

$$p = (1 - 0.9) \times 0.9 = 0.09$$

(4.2) Soit X le nombre de puces testées jusqu'à la première puce acceptée. Trouvez $P(X = 3)$ et $P(X \geq 3)$. [1 point]

SOLUTION

$$P(X = 3) = (1 - 0.9)^2 \times 0.9 = 0.009 \text{ et } P(X \geq 3) = 1 - P(X \leq 2) = 1 - (P(X = 1) + P(X = 2)) = 1 - (0.9 + 0.09) = 0.01$$

(4.3) Donnez la distribution de probabilité de X . En déduire celle de $Y = X - 4$. [1 point]

SOLUTION

$$P(X = x) = (1 - 0.9)^{x-1} \times 0.9, \quad x = 1, 2, 3, \dots$$

$$P(Y = y) = P(X - 4 = y) = P(X = 4 + y) = (1 - 0.9)^{3+y} \times 0.9, \quad y = -3, -2, -1, \dots$$

(4.4) Un système est conçu de telle sorte que sa durée de vie soit exactement la durée de vie totale des 60 puces qui le constituent. Sachant que la durée de vie moyenne d'une puce est de sept mois,

a. Calculer la durée de vie moyenne du système ainsi conçu ? [1 point]

b. Calculer la probabilité que le système fonctionne pour au moins 35 ans. [1 point]

SOLUTION

Soit $Z = D_1 + \dots + D_{60}$, où D_i est la durée de vie (en mois) de la i ème puce.

a. $E(Z) = 60 \times 7 = 420$ mois.

b. Par CLT,

$$P(Z > 35) = P(D_1 + \dots + D_{60} > 35 \times 12) \\ \approx P(N(60 \times 7, 60 \times \sigma^2) \geq 35 \times 12) = P(N(420, 60 \times \sigma^2) \geq 420) = 0.5.$$